



Instituto Tecnológico de Costa Rica

Unidad Académica de Licenciatura en Ingeniería Física

IF 4702 – Física Computacional I

# Caracterización de materiales según su deformación ante un esfuerzo: comparación de modelos de aprendizaje automático para la identificación inversa de parámetros elásticos isotrópicos y ortotrópicos

Estudiantes:

|                            |  |                                                                                  |
|----------------------------|--|----------------------------------------------------------------------------------|
| John Fred Granados Gomez   |  | <a href="mailto:johgranados@estudiantec.cr">johgranados@estudiantec.cr</a>       |
| Carlos Manuel Navarro Mora |  | <a href="mailto:canavarro@estudiantec.cr">canavarro@estudiantec.cr</a>           |
| Andrés Rodríguez Gamboa    |  | <a href="mailto:and02rodriguez@estudiantec.cr">and02rodriguez@estudiantec.cr</a> |
| Alejandro Torres Venegas   |  | <a href="mailto:a.torres.2@estudiantec.cr">a.torres.2@estudiantec.cr</a>         |

Docente:

Msc. Ricardo Solano Piedra

Docente asociado:

Lic. Frank de Jesús Marín Guillén

Grupo 01

I Semestre 2026

12 de junio del 2026

# Índice

|                                                                     |           |
|---------------------------------------------------------------------|-----------|
| <b>1. Declaración sobre el uso de herramientas de IA</b>            | <b>2</b>  |
| <b>2. Introducción</b>                                              | <b>2</b>  |
| 2.1. Contexto físico . . . . .                                      | 2         |
| 2.2. Objetivos . . . . .                                            | 3         |
| 2.3. Justificación . . . . .                                        | 3         |
| <b>3. Marco teórico</b>                                             | <b>4</b>  |
| 3.1. Elasticidad lineal y el tensor de elasticidad . . . . .        | 4         |
| 3.2. Material isotrópico . . . . .                                  | 4         |
| 3.3. Material ortotrópico . . . . .                                 | 5         |
| 3.4. El problema inverso y su identificabilidad . . . . .           | 6         |
| 3.5. Método de elementos finitos para el problema directo . . . . . | 6         |
| 3.6. Modelos de regresión y redes neuronales . . . . .              | 7         |
| <b>4. Metodología computacional</b>                                 | <b>7</b>  |
| 4.1. Selección y justificación de los métodos numéricos . . . . .   | 7         |
| 4.1.1. Problema directo . . . . .                                   | 7         |
| 4.1.2. Problema inverso . . . . .                                   | 8         |
| 4.2. Discretización del problema . . . . .                          | 8         |
| 4.2.1. Discretización espacial del problema directo . . . . .       | 8         |
| 4.2.2. Construcción de las características . . . . .                | 9         |
| 4.2.3. Discretización del espacio de parámetros . . . . .           | 9         |
| 4.3. Estabilidad y convergencia . . . . .                           | 9         |
| 4.4. Estrategia de implementación . . . . .                         | 10        |
| 4.5. Validación del modelo . . . . .                                | 10        |
| 4.6. Reproducibilidad . . . . .                                     | 10        |
| <b>5. Resultados</b>                                                | <b>11</b> |

|                                                                          |           |
|--------------------------------------------------------------------------|-----------|
| 5.1. Validación del problema directo . . . . .                           | 11        |
| 5.2. Problema isotrópico: comparación de modelos . . . . .               | 11        |
| 5.3. Identificación sobre los datos de elementos finitos . . . . .       | 13        |
| 5.4. Problema ortotrópico: comparación de modelos . . . . .              | 14        |
| <b>6. Discusión</b>                                                      | <b>17</b> |
| 6.1. Interpretación física de las tendencias . . . . .                   | 17        |
| 6.2. Efectividad de los métodos locales en el caso ortotrópico . . . . . | 17        |
| 6.3. Caso ortotrópico e implementación de anisotropía total . . . . .    | 18        |
| 6.4. Limitaciones y sensibilidad a parámetros . . . . .                  | 18        |
| <b>7. Conclusiones</b>                                                   | <b>19</b> |
| <b>Referencias</b>                                                       | <b>20</b> |
| <b>A. Apéndices</b>                                                      | <b>21</b> |
| A.1. Acceso al repositorio . . . . .                                     | 21        |

# 1. Declaración sobre el uso de herramientas de IA

Durante la elaboración de este proyecto se hizo uso de herramientas de inteligencia artificial, en particular Claude.ai y ChatGPT. Estas herramientas se emplearon con tres propósitos: la asistencia en la escritura y depuración del código en `Python` que implementa el solucionador de elementos finitos, la generación de datos y la comparación de modelos de aprendizaje automático; la mejora de la redacción de párrafos del documento, preservando las ideas originales del equipo; y la búsqueda de fuentes bibliográficas para fundamentar conceptos del marco teórico. Todas las secciones del documento, el código y los resultados fueron revisados críticamente, ejecutados, verificados contra las soluciones analíticas de referencia y modificados a criterio de los integrantes del grupo de trabajo hasta obtener la versión final presente en este documento. La responsabilidad académica del contenido final recae enteramente en el equipo.

## 2. Introducción

### 2.1. Contexto físico

En el campo de la ingeniería y las ciencias de los materiales es fundamental contar con técnicas que permitan una caracterización precisa del comportamiento mecánico de los materiales. Este comportamiento se describe mediante un modelo constitutivo que relaciona los esfuerzos con las deformaciones del material a través de un conjunto de parámetros elásticos, los cuales determinan completamente la respuesta del material en el régimen elástico lineal y resultan indispensables en el diseño estructural, la simulación numérica y el desarrollo de nuevos materiales [1], [2].

La determinación de estos parámetros a partir de mediciones de campo constituye un problema inverso: en lugar de calcular la respuesta del material conociendo sus propiedades, se busca recuperar las propiedades a partir de la respuesta observada [3]. Los métodos clásicos de identificación, como el ajuste de modelos de elementos finitos por mínimos cuadrados, requieren resolver repetidamente el problema directo y se vuelven costosos conforme aumenta el número de parámetros a identificar [4]. Los métodos de aprendizaje automático ofrecen una alternativa: una vez entrenado, un modelo de regresión evalúa el mapeo inverso de forma prácticamente instantánea [5].

La complejidad del problema inverso depende directamente de la clase de simetría del material. Un material isotrópico, cuya respuesta es idéntica en todas las direcciones, queda caracterizado por únicamente dos constantes independientes. Un material ortotrópico, con tres planos de simetría mutuamente perpendiculares como ocurre en la madera, los laminados compuestos y los metales laminados con textura cristalográfica, requiere nueve constantes. Un material anisotrópico general requiere hasta veintiuna [6]. Este proyecto estudia cómo se comportan distintos modelos de aprendizaje automático al escalar el problema de la clase isotrópica a la ortotrópica, y discute el salto metodológico que implicaría la anisotropía total.

## 2.2. Objetivos

### Objetivo general

Implementar y validar un flujo de trabajo computacional reproducible que compare sistemáticamente modelos de aprendizaje automático, incluyendo redes neuronales de distintas profundidades, para la identificación inversa de los parámetros elásticos de materiales linealmente isotrópicos y ortotrópicos a partir de datos de esfuerzo y deformación generados por el método de elementos finitos, evaluando su desempeño en términos de precisión, convergencia, estabilidad y costo computacional.

### Objetivos específicos

1. Presentar el modelo constitutivo de elasticidad lineal para las clases de simetría isotrópica y ortotrópica, implementar en `Python` un solucionador de elementos finitos de código abierto para el problema directo de compresión uniaxial, y validarlo contra la solución analítica de referencia.
2. Entrenar ocho modelos de regresión, desde regresión lineal hasta redes neuronales multicapa, para la identificación de los parámetros  $(E, \nu)$  en el caso isotrópico y  $(E_1, E_2, E_3, \nu_{12}, \nu_{13}, \nu_{23})$  en el caso ortotrópico, utilizando conjuntos de datos sintéticos generados con el modelo directo y contaminados con ruido representativo de mediciones experimentales.
3. Evaluar cuantitativamente el desempeño de cada modelo mediante métricas de precisión ( $R^2$ , RMSE, MAPE), validación cruzada y costo computacional de entrenamiento e inferencia, verificando la capacidad de identificación sobre los campos de elementos finitos de cuatro materiales de ingeniería con propiedades nominales conocidas.

## 2.3. Justificación

La determinación precisa de los parámetros constitutivos a partir de datos de deformación sigue siendo, en la práctica, un proceso que carece de herramientas abiertas y validadas [3]. Este proyecto aporta una implementación completamente libre, desde la generación de los datos por elementos finitos hasta la identificación de parámetros, construida sobre `Python` y las bibliotecas NumPy, SciPy, scikit-learn y scikit-fem [7], [8], [9], [10]. Esta independencia de licencias comerciales resulta especialmente relevante en el contexto latinoamericano, donde la dependencia de software propietario como ANSYS, COMSOL o SOLIDWORKS representa una barrera económica para grupos de investigación con presupuesto limitado.

En relación con la versión presentada en el avance del proyecto, este documento incorpora dos cambios sustanciales motivados por la retroalimentación y por las dificultades técnicas encontradas. Primero, la generación de datos migró de SOLIDWORKS, cuya edición estudiantil bloquea el acceso programático a los resultados de simulación, a un solucionador de elementos finitos propio implementado con la biblioteca

de código abierto scikit-fem, lo cual elimina por completo la dependencia de licencias y convierte la generación de los datos en parte verificable del trabajo computacional. Segundo, el alcance se amplió del caso isotrópico de dos parámetros, cuyo mapeo inverso resulta relativamente sencillo, al caso ortotrópico de seis parámetros identificables, donde la comparación entre familias de modelos de aprendizaje automático produce diferencias cualitativas de comportamiento que constituyen el resultado científico central del proyecto.

El proyecto integra de forma natural los contenidos del curso de Física Computacional I: la resolución numérica de ecuaciones diferenciales parciales mediante elementos finitos, el aprendizaje automático supervisado con scikit-learn, el muestreo aleatorio de espacios de parámetros, el análisis de convergencia y estabilidad numérica, y las buenas prácticas de reproducibilidad computacional.

### 3. Marco teórico

#### 3.1. Elasticidad lineal y el tensor de elasticidad

El tensor de esfuerzo de Cauchy  $\mathbf{T}$  puede expresarse como función del tensor de deformación infinitesimal  $\mathbf{E}$ , con  $\mathbf{T}(\mathbf{0}) = \mathbf{0}$ . En el régimen de pequeñas deformaciones se asume una relación lineal entre ambos, que en notación de Einstein se escribe [1]

$$T_{ij} = C_{ijkl} E_{kl} \quad (1)$$

donde  $C_{ijkl}$  son las componentes del tensor de elasticidad de cuarto orden, que en principio posee  $3^4 = 81$  coeficientes. La simetría del tensor de deformación ( $E_{kl} = E_{lk}$ ) implica  $C_{ijkl} = C_{ijlk}$  y reduce el conteo a 54; la simetría del tensor de esfuerzos ( $T_{ij} = T_{ji}$ ) implica  $C_{ijkl} = C_{jikl}$  y lo reduce a 36; finalmente, la existencia de una función de energía de deformación  $U(E_{kl})$  tal que  $T_{ij} = \partial U / \partial E_{ij}$  impone la simetría mayor  $C_{ijkl} = C_{klij}$ , dejando 21 coeficientes independientes [1]. Este es el caso anisotrópico general, correspondiente a un material triclinico sin ningún plano de simetría [6].

La presencia de simetrías materiales reduce progresivamente este número. La jerarquía relevante para este proyecto es la siguiente [6]: el material anisotrópico general (triclinico) requiere 21 constantes; el material ortotrópico, con tres planos de simetría mutuamente perpendiculares, requiere 9; el material transversalmente isotrópico, con un eje de simetría rotacional, requiere 5; y el material isotrópico, indistinguible bajo cualquier rotación, requiere únicamente 2.

#### 3.2. Material isotrópico

Para un material isotrópico el tensor de elasticidad se expresa como combinación de los tensores isotrópicos de cuarto orden, lo que permite reescribir la ecuación (1) como  $T_{ij} = \lambda E_{kk} \delta_{ij} + 2\mu E_{ij}$ , donde

$\lambda$  y  $\mu$  son las constantes de Lamé y  $\delta_{ij}$  la delta de Kronecker. Invirtiendo esta relación se obtiene la forma utilizada en este trabajo [1]:

$$E_{ij} = \frac{1}{E_Y} [(1 + \nu) T_{ij} - \nu T_{kk} \delta_{ij}] \quad (2)$$

donde el módulo de Young  $E_Y$  y el coeficiente de Poisson  $\nu$  se relacionan con las constantes de Lamé mediante

$$E_Y = \frac{\mu(3\lambda + 2\mu)}{\lambda + \mu}, \quad (3a) \quad \nu = \frac{\lambda}{2(\lambda + \mu)}. \quad (3b)$$

Bajo compresión uniaxial en la dirección  $y$  con esfuerzo aplicado  $\sigma_{yy} = -F/A$ , la ecuación (2) produce la solución analítica de referencia

$$\varepsilon_{yy} = \frac{\sigma_{yy}}{E_Y}, \quad (4a) \quad \varepsilon_{xx} = \varepsilon_{zz} = -\nu \varepsilon_{yy}, \quad (4b)$$

de la cual se despeja directamente el módulo de Young y el coeficiente de Poisson:

$$E_Y = \sigma_{yy}/\varepsilon_{yy}, \quad (5a) \quad \nu = -\varepsilon_{xx}/\varepsilon_{yy}. \quad (5b)$$

Esta solución cerrada permite validar tanto el solucionador de elementos finitos como los modelos de aprendizaje automático<sup>1</sup>.

### 3.3. Material ortotrópico

Para un material ortotrópico con los ejes materiales alineados con los ejes coordenados, la ley constitutiva se escribe de forma compacta en notación de Voigt mediante la matriz de flexibilidad (*compliance*)  $\mathbf{S}$ , que relaciona deformaciones con esfuerzos [6]:

$$\begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \gamma_{23} \\ \gamma_{13} \\ \gamma_{12} \end{pmatrix} = \begin{pmatrix} 1/E_1 & -\nu_{21}/E_2 & -\nu_{31}/E_3 & 0 & 0 & 0 \\ -\nu_{12}/E_1 & 1/E_2 & -\nu_{32}/E_3 & 0 & 0 & 0 \\ -\nu_{13}/E_1 & -\nu_{23}/E_2 & 1/E_3 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1/G_{23} & 0 & 0 \\ 0 & 0 & 0 & 0 & 1/G_{13} & 0 \\ 0 & 0 & 0 & 0 & 0 & 1/G_{12} \end{pmatrix} \begin{pmatrix} \sigma_1 \\ \sigma_2 \\ \sigma_3 \\ \tau_{23} \\ \tau_{13} \\ \tau_{12} \end{pmatrix} \quad (6)$$

con nueve constantes independientes: tres módulos de Young  $E_1, E_2, E_3$ , tres coeficientes de Poisson independientes  $\nu_{12}, \nu_{13}, \nu_{23}$  y tres módulos cortantes  $G_{12}, G_{13}, G_{23}$ . La simetría de  $\mathbf{S}$  impone las relaciones recíprocas  $\nu_{ij}/E_i = \nu_{ji}/E_j$ , de modo que los coeficientes  $\nu_{21}, \nu_{31}, \nu_{32}$  no son independientes.

No cualquier combinación de estas constantes es físicamente admisible. La estabilidad termodinámica del material exige que la energía de deformación sea definida positiva, lo cual se traduce en que la matriz

<sup>1</sup>claramente, solo valida la implementación para el caso isotrópico.

$\mathbf{S}$  sea definida positiva. Para materiales ortotrópicos estas condiciones fueron establecidas por Lempriere [11] y se expresan como

$$|\nu_{ij}| < \sqrt{E_i/E_j}, \quad (7)$$

$$1 - \nu_{12}\nu_{21} - \nu_{23}\nu_{32} - \nu_{13}\nu_{31} - 2\nu_{21}\nu_{32}\nu_{13} > 0. \quad (8)$$

Estas desigualdades se utilizan en este trabajo como criterio de rechazo durante el muestreo del espacio de parámetros, garantizando que el conjunto de entrenamiento contenga únicamente materiales físicamente realizables.

### 3.4. El problema inverso y su identificabilidad

Un aspecto importante del caso ortotrópico es la identificabilidad: un único ensayo de compresión uniaxial en la dirección, por ejemplo, 2 “activa” únicamente la segunda columna de la matriz de la ecuación (6), de modo que solo  $E_2$ ,  $\nu_{12}$  (vía la relación recíproca) y  $\nu_{23}$  tienen respuesta no nula. Las seis constantes restantes son invisibles para ese experimento, sin importar la calidad de los datos o del modelo de regresión [3].

Por esta razón, en este trabajo se adopta un protocolo de tres ensayos uniaxiales independientes, con cargas aplicadas sucesivamente en las direcciones 1, 2 y 3. Así se puede observar la respuesta de las tres columnas normales de  $\mathbf{S}$  y permite identificar seis de las nueve constantes:  $E_1, E_2, E_3, \nu_{12}, \nu_{13}$  y  $\nu_{23}$ . Los módulos cortantes  $G_{12}, G_{13}, G_{23}$  ocupan el bloque desacoplado de la matriz y solo responden ante esfuerzos cortantes, por lo que su identificación requeriría ensayos de torsión o cizalladura, los cuales quedan fuera del alcance de este proyecto.

### 3.5. Método de elementos finitos para el problema directo

El problema directo de elasticidad lineal estática consiste en resolver la ecuación de equilibrio:

$$\nabla \cdot \boldsymbol{\sigma} = \mathbf{0}, \quad (9)$$

la cual, en el dominio establecido (la pieza de interés), está sujeta a condiciones de frontera de Dirichlet (desplazamiento impuesto) y de Neumann (tracción impuesta). El método de elementos finitos discretiza la formulación débil del problema: el dominio se divide en elementos, el campo de desplazamiento se aproxima mediante funciones de forma polinomiales por trozos y el problema se reduce a un sistema lineal  $\mathbf{K}\mathbf{u} = \mathbf{f}$ , donde  $\mathbf{K}$  es la matriz de rigidez global [12]. En este trabajo se emplean elementos  $P_1$  (tetraedros lineales), para los cuales el gradiente del desplazamiento, y por tanto la deformación, es constante dentro de cada elemento. La teoría de convergencia establece que para elementos  $P_1$  el error del campo de desplazamiento

converge como  $\mathcal{O}(h^2)$  y el de las deformaciones como  $\mathcal{O}(h)$ , con  $h$  el tamaño característico del elemento [12].

### 3.6. Modelos de regresión y redes neuronales

La identificación de parámetros se formula como un problema de regresión supervisada: dado un vector de características  $\mathbf{x}$  construido a partir de los campos medidos, predecir el vector de parámetros  $\mathbf{y}$ . Los ocho modelos comparados pertenecen a cuatro familias distintas.

La regresión lineal ajusta un modelo  $\mathbf{y} = \mathbf{W}\mathbf{x} + \mathbf{b}$  por mínimos cuadrados y sirve como línea base. La regresión polinomial expande las características a todos los productos de grado dos (i.e. regresión cuadrática) y ajusta una regresión de cresta (Ridge), capturando interacciones cuadráticas. Los métodos basados en vecindad y árboles incluyen los  $k$  vecinos más cercanos, que predice promediando las muestras de entrenamiento más próximas; los bosques aleatorios, que agregan árboles de decisión entrenados sobre subconjuntos aleatorios de datos y características [13]; y el aumento de gradiente (gradient boosting, en inglés), que construye un ensamble aditivo de árboles donde cada uno corrige los residuos del anterior [14]. Estos métodos particionan el espacio de entrada y son intrínsecamente locales, lo que condiciona su comportamiento al crecer la dimensionalidad.

Las redes neuronales multicapa (Multi-Layer perceptron, MLP, en inglés) componen transformaciones afines con funciones de activación no lineales; el teorema de aproximación universal garantiza que una red con suficientes neuronas puede aproximar cualquier función continua sobre un compacto [15], [16]. Se comparan tres arquitecturas de profundidad creciente, con activación tangente hiperbólica, apropiada para mapeos suaves con entradas estandarizadas, entrenadas con el optimizador Adam [17] y detención temprana sobre un conjunto de validación interno para prevenir el sobreajuste.

## 4. Metodología computacional

El flujo de trabajo se compone de dos programas en Python: `Simul_FEM.py`, que genera los datos del problema directo mediante elementos finitos, y `Comparacion_ML.py`, que construye los conjuntos de entrenamiento, entrena los ocho modelos y produce todas las métricas, tablas y figuras de este documento.

### 4.1. Selección y justificación de los métodos numéricos

#### 4.1.1. Problema directo

Para la generación de los datos isotrópicos se implementó un solucionador de elasticidad lineal estática con la biblioteca de código abierto scikit-fem [10], que ensambla la forma débil del operador de elasticidad

y produce el sistema  $\mathbf{Ku} = \mathbf{f}$ , resuelto con el método directo disperso de SciPy [8]. Se eligieron elementos tetraédricos lineales  $P_1$  por tres razones: la geometría cúbica del dominio admite un mallado estructurado trivial; el costo por simulación debe ser bajo, pues se requieren 400 soluciones del problema directo; y la solución esperada es un campo casi homogéneo, para el cual los elementos de bajo orden son adecuados. La alternativa de elementos cuadráticos  $P_2$  reduciría el error de las deformaciones de  $\mathcal{O}(h)$  a  $\mathcal{O}(h^2)$  a cambio de multiplicar varias veces el número de grados de libertad; el estudio de convergencia del apartado 4.3 muestra que la precisión alcanzada con  $P_1$  es suficiente para el propósito del proyecto.

Las condiciones de frontera replican un ensayo de compresión: la cara inferior ( $y = 0$ ) se empotra con una condición de Dirichlet homogénea y sobre la cara superior ( $y = L$ ) se aplica una presión uniforme  $-F/A$  como condición de Neumann. El procesamiento calcula las deformaciones elemento a elemento a partir de los gradientes de las funciones de forma, las proyecta a los nodos mediante promediado y obtiene los esfuerzos con la ley de Hooke, exportando por cada caso un archivo CSV con la posición, los seis esfuerzos, las seis deformaciones y los tres desplazamientos de cada nodo.

#### 4.1.2. Problema inverso

La selección de modelos cubre deliberadamente cuatro familias con sesgos inductivos distintos, descritas en el marco teórico, para responder no solo cuál modelo es más preciso sino por qué. La regresión lineal se incluye como línea base diagnóstica: el mapeo inverso  $E_Y = \sigma/\varepsilon$  es un cociente entre características, intrínsecamente no lineal, y la magnitud de su error cuantifica esa no linealidad. La regresión cuadrática es un incremento de complejidad y permite cuantificar parte de esa no linealidad. Los tres métodos de árboles y vecindad (KNN, bosques aleatorios, aumento de gradiente) son los métodos de regresión no paramétrica estudiados en el curso y dominantes en la práctica sobre datos tabulares. Las tres redes neuronales de profundidad creciente, de una a tres capas ocultas, permiten estudiar el efecto de la capacidad del modelo. Todos los modelos comparten exactamente el mismo preprocesamiento, estandarización de entradas y salidas mediante `StandardScaler` dentro de un `Pipeline` de scikit-learn [9], lo cual garantiza que las diferencias observadas se deban a los modelos y no al tratamiento de los datos. La estandarización de las salidas es indispensable porque los módulos de Young (decenas a centenas de GPa) y los coeficientes de Poisson (orden 0,3) difieren en dos órdenes de magnitud.

### 4.2. Discretización del problema

#### 4.2.1. Discretización espacial del problema directo

El dominio es un cubo de lado  $L = 10\text{mm}$  discretizado con una malla estructurada de  $10 \times 10 \times 10$  divisiones por arista, es decir  $h = 1\text{mm}$ , que produce 1331 nodos, 6000 tetraedros y 3993 grados de libertad. Se simulan 100 magnitudes de carga por material,  $F \in \{10, 20, \dots, 1000\}\text{N}$ , para cuatro materiales isotrópicos de ingeniería con propiedades nominales conocidas: acero AISI 1020 ( $E = 200\text{GPa}$ ,

$\nu = 0,29$ ), hierro dúctil ( $E = 120$  GPa,  $\nu = 0,31$ ), aluminio 6061 ( $E = 69$  GPa,  $\nu = 0,33$ ) y la aleación de titanio Ti-6Al-4V ( $E = 114$  GPa,  $\nu = 0,34$ ), para un total de 400 simulaciones.

#### 4.2.2. Construcción de las características

En el caso isotrópico cada simulación se condensa en cinco características físicas: el esfuerzo axial aplicado  $-F/A$ , los promedios volumétricos de las deformaciones  $\bar{\varepsilon}_{yy}$ ,  $\bar{\varepsilon}_{xx}$  y  $\bar{\varepsilon}_{zz}$ , y el desplazamiento axial máximo  $|v|_{\text{máx}}$ . Los promedios se calculan únicamente sobre el subvolumen  $0,25L \leq y \leq 0,95L$ , en aplicación del principio de Saint-Venant: la condición de empotramiento de la base restringe la expansión lateral en una capa de borde. Este efecto sesgaría los cálculos de la deformación transversal y, con ella, la identificación de  $\nu$ .

#### 4.2.3. Discretización del espacio de parámetros

Los conjuntos de entrenamiento se generan muestreando aleatoriamente el espacio de parámetros con el modelo directo analítico, y contaminando las características con ruido gaussiano relativo del 1 %, representativo de la incertidumbre de técnicas de medición de campo completo como la correlación digital de imágenes [4]. En el caso isotrópico se generan 8000 muestras con  $E \sim \mathcal{U}(50, 280)$  GPa,  $\nu \sim \mathcal{U}(0,20, 0,40)$  y  $F \sim \mathcal{U}(10, 1000)$  N. En el caso ortotrópico se generan 12 000 muestras con  $E_i \sim \mathcal{U}(60, 250)$  GPa y  $\nu_{ij} \sim \mathcal{U}(0,10, 0,45)$ , aplicando muestreo con rechazo según las condiciones de estabilidad de las ecuaciones (7) y (8); cada muestra comprende el protocolo de tres ensayos uniaxiales con esfuerzos  $\sigma \sim \mathcal{U}(0,1, 10)$  MPa, produciendo doce características (nueve deformaciones y tres esfuerzos) y seis parámetros objetivo. En ambos problemas se reserva el 20 % de las muestras como conjunto de prueba no visto durante el entrenamiento.

### 4.3. Estabilidad y convergencia

La convergencia del solucionador de elementos finitos se verificó mediante refinamiento de malla: al pasar de 10 a 14 divisiones por arista, el error de la identificación directa de  $E$  a partir de los campos disminuye de 1,05 % a 0,84 %, un descenso monótono consistente con la convergencia  $\mathcal{O}(h)$  de las deformaciones en elementos  $P_1$ . El error residual a la malla de trabajo, del orden del 1 %, queda registrado como sesgo sistemático de los datos y reaparece en la evaluación final de los modelos.

La estabilidad del entrenamiento de las redes neuronales se controla mediante detención temprana: el 15 % del conjunto de entrenamiento se reserva como validación interna y el entrenamiento se detiene cuando la pérdida de validación deja de mejorar durante 25 iteraciones, lo que previene el sobreajuste sin necesidad de fijar manualmente el número de épocas. La robustez estadística de todas las métricas se evalúa mediante validación cruzada de tres particiones sobre el conjunto de entrenamiento, reportando

la media y la desviación estándar del RMSE; la pequeña dispersión observada entre particiones confirma que los resultados no dependen de una partición particular de los datos.

#### 4.4. Estrategia de implementación

El flujo del programa de simulación es el siguiente: se construye la malla y se precálculan, una única vez, los gradientes de las funciones de forma de todos los elementos en forma vectorizada con NumPy [7], puesto que dependen solo de la geometría; para cada material y cada carga se ensambla la matriz de rigidez, se imponen las condiciones de frontera, se resuelve el sistema disperso, se posprocesan deformaciones y esfuerzos y se exporta el CSV. La vectorización del posprocesamiento, que evita todo bucle sobre elementos mediante operaciones de álgebra tensorial por lotes (`numpy.linalg.inv` sobre arreglos de matrices), reduce el tiempo por simulación a aproximadamente medio segundo, completando las 400 simulaciones en menos de cuatro minutos en un equipo de escritorio.

El programa de comparación define los ocho modelos mediante una función fábrica que envuelve cada estimador en el mismo `Pipeline` de estandarización, entrena y evalúa cada uno sobre las mismas particiones, ejecuta la validación cruzada, realiza la identificación sobre los datos de elementos finitos y exporta automáticamente todas las tablas en formato CSV y  $\text{\LaTeX}$  y las figuras en formato PDF. El código no se incluye en el cuerpo del documento; ambos programas, con documentación interna completa de parámetros y flujo, acompañan la entrega.

#### 4.5. Validación del modelo

La validación se realizó en tres niveles independientes. Primero, el solucionador de elementos finitos se validó contra la solución analítica de las ecuaciones (4a) y (4b): el esfuerzo axial promedio en el subvolumen de Saint-Venant reproduce el valor aplicado con un error del 0,5 % y las deformaciones con errores del orden del 1 %, como se detalla en la sección de resultados. Segundo, los modelos de aprendizaje automático se validaron sobre el conjunto de prueba sintético, datos nunca vistos durante el entrenamiento, mediante  $R^2$ , RMSE y MAPE por parámetro. Tercero, y de forma decisiva, los modelos entrenados exclusivamente con datos analíticos se aplicaron a los campos de elementos finitos de los cuatro materiales reales, comparando los parámetros identificados contra los valores nominales conocidos; esta prueba cruzada entre fuentes de datos independientes constituye la validación física del enfoque completo.

#### 4.6. Reproducibilidad

Todos los generadores aleatorios del estudio utilizan la semilla global 2026, de modo que los conjuntos de datos sintéticos, las particiones y la inicialización de las redes son exactamente reproducibles. Los programas registran las versiones de las bibliotecas utilizadas (NumPy 2.4, pandas 3.0, SciPy 1.17, scikit-learn 1.8, scikit-fem 12.0 sobre Python 3.12 o superior) y todos los parámetros del estudio, incluyendo

rangos de muestreo, nivel de ruido, arquitecturas e hiperparámetros, están centralizados en el encabezado de cada programa y documentados en esta sección. Los datos intermedios se almacenan en archivos CSV con encabezados autodescriptivos, y todas las figuras y tablas de este documento se generan programáticamente, sin intervención manual, al ejecutar los dos programas en orden. Los tiempos de cómputo reportados corresponden a un procesador de escritorio de seis núcleos; los valores absolutos varían con el equipo, pero las relaciones entre modelos se preservan.

## 5. Resultados

### 5.1. Validación del problema directo

El cuadro 1 compara los campos de elementos finitos contra la solución analítica de las ecuaciones (4a) y (4b) para el caso representativo del acero AISI 1020 bajo  $F = 500$  N. El esfuerzo axial promedio en el subvolumen de Saint-Venant reproduce el valor aplicado de  $-5,000$  MPa con un error del 0,51 %, y la identificación directa de los parámetros a partir de los campos, sin intervención de ningún modelo de aprendizaje, recupera  $E$  con un error del 1,05 % y  $\nu$  con 1,70 %. Estos valores establecen el piso de error de los datos: ningún modelo entrenado sobre el mapeo analítico exacto puede identificar los parámetros de los datos FEM con un error menor al sesgo de discretización propio de esos datos.

Cuadro 1: Validación del solucionador de elementos finitos contra la solución analítica (AISI 1020,  $F = 500$  N, malla de  $10^3$  divisiones). Promedios sobre el subvolumen de Saint-Venant.

| Cantidad                                      | FEM    | Analítica | Error [%] |
|-----------------------------------------------|--------|-----------|-----------|
| $\bar{\sigma}_{yy}$ [MPa]                     | -4,974 | -5,000    | 0,51      |
| $\bar{\varepsilon}_{yy}$ [ $\times 10^{-5}$ ] | -2,474 | -2,500    | 1,04      |
| $\bar{\varepsilon}_{xx}$ [ $\times 10^{-6}$ ] | 7,053  | 7,250     | 2,72      |
| $E$ identificado [GPa]                        | 202,1  | 200,0     | 1,05      |
| $\nu$ identificado                            | 0,2851 | 0,2900    | 1,70      |

### 5.2. Problema isotrópico: comparación de modelos

El cuadro 2 resume el desempeño de los ocho modelos sobre el conjunto de prueba sintético del problema isotrópico, y la figura 1 presenta el RMSE por parámetro en escala logarítmica. Tres observaciones estructuran el resultado. Primero, la regresión lineal alcanza apenas  $R^2 = 0,588$ , con un error porcentual del 26,8 % en  $E$ : el mapeo inverso es esencialmente no lineal y un modelo afín no puede representarlo. Segundo, todos los modelos no lineales superan  $R^2 = 0,96$ , con los métodos de árboles y vecindad agrupados en torno a un RMSE de validación cruzada de 4 a 5 GPa. Tercero, las redes profundas dominan: la MLP de tres capas alcanza  $R^2 = 0,9956$  con RMSE de 3,61 GPa en  $E$  (MAPE 1,28 %) y 0,0044 en  $\nu$

(MAPE 0,95 %), y la figura 2 muestra sus diagramas de paridad sobre el conjunto de prueba.

Cuadro 2: Comparación de modelos en el problema isotrópico sobre el conjunto de prueba sintético ( $N_{\text{prueba}} = 1600$ ). RMSE CV es la media  $\pm$  desviación estándar de la validación cruzada de 3 particiones (variables estandarizadas combinadas). Se subraya el mejor resultado en cada columna.

| Modelo            | RMSE $E$ [GPa] | RMSE $\nu$ | MAPE $E$ [%] | MAPE $\nu$ [%] | $R^2$ | $t_{\text{ent}}$ [s] |
|-------------------|----------------|------------|--------------|----------------|-------|----------------------|
| Lineal            | 41,68          | 0,0378     | 26,76        | 10,09          | 0,588 | < 0,1                |
| Polinomial-2      | 29,01          | 0,0263     | 17,19        | 6,42           | 0,801 | < 0,1                |
| KNN               | 5,61           | 0,0108     | 2,57         | 2,69           | 0,979 | < 0,1                |
| Bosque Aleatorio  | 6,61           | 0,0090     | 3,12         | 2,12           | 0,983 | 5,7                  |
| Grad. Boosting    | 6,10           | 0,0089     | 2,45         | 2,12           | 0,984 | 0,4                  |
| MLP (32)          | 10,51          | 0,0118     | 3,54         | 2,08           | 0,967 | 5,8                  |
| MLP (64, 64)      | 4,02           | 0,0052     | 1,40         | 1,06           | 0,994 | 8,9                  |
| MLP (128, 64, 32) | 3,61           | 0,0044     | 1,28         | 0,95           | 0,996 | 9,4                  |

RMSE en prueba por modelo: problema isotropico




Figura 1: RMSE por parámetro y por modelo en el conjunto de prueba del problema isotrópico (escala logarítmica). La brecha entre los modelos lineales y los no lineales cuantifica la no linealidad del mapeo inverso.

Paridad en prueba: MLP (128,64,32) (isotrópico)




Figura 2: Diagramas de paridad del mejor modelo, MLP (128, 64, 32), sobre el conjunto de prueba isotrópico. La dispersión residual en torno a la identidad corresponde al ruido del 1 % inyectado en las características.

### 5.3. Identificación sobre los datos de elementos finitos

La prueba más relevante consiste en aplicar los modelos, entrenados exclusivamente con el mapeo analítico, a los campos FEM de los cuatro materiales. El cuadro 3 presenta el error relativo de identificación promediado sobre los cien casos de carga de cada material, y la figura 3 lo desglosa por material y modelo. El aumento de gradiente resulta el más preciso en  $E$  (error promedio 1,30 %) y en  $\nu$  (0,58 %), seguido de cerca por la MLP profunda (1,53 % y 1,25 %). Estos errores son del mismo orden que el sesgo de discretización del cuadro 1, lo que indica que los mejores modelos ya operan en el límite impuesto por la calidad de los datos y no por su propia capacidad.

Cuadro 3: Error relativo de identificación sobre los datos FEM, promediado sobre los cuatro materiales y los 100 casos de carga por material. Se subraya el mejor resultado de la columna.

| Modelo            | Error en $E$ [%] | Error en $\nu$ [%] |
|-------------------|------------------|--------------------|
| Grad. Boosting    | <b>1,30</b>      | <b>0,58</b>        |
| MLP (128, 64, 32) | 1,53             | 1,25               |
| MLP (64, 64)      | 2,13             | 1,32               |
| KNN               | 2,84             | 0,54               |
| Bosque Aleatorio  | 2,96             | 0,65               |
| MLP (32)          | 3,47             | 1,17               |
| Polinomial-2      | 8,44             | 0,81               |
| Lineal            | 20,92            | 1,96               |

Error de identificación sobre los casos FEM reales




Figura 3: Error relativo de identificación de  $E$  y  $\nu$  sobre los campos FEM, desglosado por material y modelo (escala logarítmica).

#### 5.4. Problema ortotrópico: comparación de modelos

El cuadro 4 y las figuras 4 y 5 presentan la comparación en el problema ortotrópico de seis parámetros. El panorama cambia cualitativamente respecto al caso isotrópico: los métodos locales pierden efectividad significativamente. KNN cae a  $R^2 = 0,642$  y el bosque aleatorio a 0,681, con errores porcentuales del 15 al 23 % en los módulos, peores incluso que la regresión polinomial. En contraste, el aumento de gradiente ( $R^2 = 0,989$ ) y las redes profundas ( $R^2 = 0,991$ ) mantienen errores porcentuales del 2 al 3 % en los seis parámetros. La figura 6 muestra la paridad de la MLP de tres capas en los seis parámetros, y la figura 7 resume el compromiso entre costo de entrenamiento y precisión en ambos problemas.

Cuadro 4: Comparación de modelos en el problema ortotrópico sobre el conjunto de prueba sintético ( $N_{\text{prueba}} = 2400$ ). Se reporta el MAPE promedio de los tres módulos de Young y de los tres coeficientes de Poisson. Se subraya el mejor resultado de cada columna.

| Modelo            | MAPE $E_i$ [%] | MAPE $\nu_{ij}$ [%] | $R^2$ | RMSE CV          | $t_{\text{ent}}$ [s] |
|-------------------|----------------|---------------------|-------|------------------|----------------------|
| Lineal            | 19,30          | 20,19               | 0,689 | $21,04 \pm 0,24$ | < 0,1                |
| Polinomial-2      | 11,28          | 11,20               | 0,877 | $13,51 \pm 0,22$ | < 0,1                |
| KNN               | 18,75          | 21,76               | 0,642 | $23,33 \pm 0,15$ | < 0,1                |
| Bosque Aleatorio  | 19,29          | 19,78               | 0,681 | $23,05 \pm 0,23$ | 19,3                 |
| Grad. Boosting    | 2,75           | 3,05                | 0,989 | $4,22 \pm 0,18$  | 2,0                  |
| MLP (32)          | 3,95           | 4,17                | 0,974 | $6,54 \pm 0,18$  | 8,5                  |
| MLP (64, 64)      | 2,26           | 2,36                | 0,991 | $4,17 \pm 0,18$  | 12,0                 |
| MLP (128, 64, 32) | 2,38           | 2,49                | 0,991 | $4,35 \pm 0,23$  | 14,4                 |




Figura 4: RMSE de los tres módulos de Young por modelo en el problema ortotrópico (escala logarítmica).




Figura 5: RMSE de los tres coeficientes de Poisson independientes por modelo en el problema ortotrópico (escala logarítmica).




Figura 6: Diagramas de paridad del mejor modelo en el problema ortotrópico, MLP (128, 64, 32), para los seis parámetros identificables del protocolo de tres ensayos uniaxiales.




Figura 7: Compromiso entre tiempo de entrenamiento y RMSE de validación cruzada para los ocho modelos en ambos problemas (escalas logarítmicas). El aumento de gradiente ocupa consistentemente el frente de Pareto.

En cuanto al costo de inferencia, relevante para aplicaciones en tiempo real, todos los modelos predicen en fracciones de milisegundo por muestra; las redes neuronales, una vez entrenadas, evalúan en 1 a 10  $\mu$ s por muestra, lo que confirma la ventaja característica del enfoque de aprendizaje frente a los métodos

inversos iterativos clásicos, cuyo costo por evaluación equivale a múltiples soluciones del problema directo [4].

## 6. Discusión

### 6.1. Interpretación física de las tendencias

El alto error de la regresión lineal no se debe a un defecto de implementación, sino tipo de sistema modelado: el mapeo inverso contiene cocientes entre características,  $E_Y = \sigma_{yy}/\varepsilon_{yy}$  y  $\nu = -\varepsilon_{xx}/\varepsilon_{yy}$ , y un cociente no admite representación afín sobre un rango amplio de cargas. La regresión polinomial de grado dos mejora pero no resuelve el problema, pues el cociente tampoco es un polinomio. Los modelos verdaderamente no lineales, en cambio, aprenden el mapeo con errores cercanos al límite impuesto por el ruido inyectado: con un 1 % de ruido en las deformaciones, la propagación directa de incertidumbre sobre el cociente predice un error del orden del 1,4 % en los parámetros, exactamente el orden del MAPE alcanzado por las redes profundas.

El sesgo residual en la identificación del coeficiente de Poisson sobre los datos obtenidos por FEM se debe principalmente al empotramiento de la base. Este impide la expansión lateral del material en su vecindad, generando una capa de borde donde  $\varepsilon_{xx}$  es menor que el valor de campo libre. Aunque el filtro de Saint-Venant excluye la mayor parte de esta capa, su cola “contamina” ligeramente el promedio y reduce el valor obtenido (0,2851 contra 0,2900 nominal en el AISI 1020). Este es un sesgo de la implementación, no de los modelos de regresión y afecta por igual a todos los métodos comparados, como confirma el hecho de que los errores de los mejores modelos coincidan con el sesgo de los propios datos cuantificado en la validación.

### 6.2. Efectividad de los métodos locales en el caso ortotrópico

Un resultado significativo de este análisis es la divergencia cualitativa entre familias de modelos al pasar del caso isotrópico, con 5 características y 2 parámetros al ortotrópico, con 12 características y 6 parámetros. KNN y el bosque aleatorio, que en el caso isotrópico competían con las redes, se ven considerablemente reducidas, con  $R^2 \approx 0,65$ . Esto se debe principalmente a la dimensionalidad que afecta a los métodos locales: KNN predice promediando vecinos, pero en doce dimensiones la densidad de las 12 000 muestras de entrenamiento es insuficiente para que los vecinos más cercanos sean representativos, pues la distancia al vecino más próximo crece y el promedio local mezcla el efecto de propiedades distintas [16]. El bosque aleatorio, construido sobre particiones del espacio alineadas con los ejes, sufre un problema similar y además es incapaz de extrapolar fuera de los datos de entrenamiento. El aumento de gradiente escapa parcialmente a esta limitación porque su construcción aditiva secuencial, donde cada árbol corrige residuos globales, actúa como un ajuste de funciones más que como un promedio local [14]. Las redes

neuronales, que aprenden representaciones globales y suaves del mapeo, son las menos afectadas por el aumento de dimensionalidad [15].

Este cambio implica que la elección del modelo es poco crítica en casos de baja dimensionalidad (alta simetría), pero se vuelve mucho más importante en situaciones menos simétricas, que es precisamente la dirección de interés en la caracterización de materiales compuestos.

### 6.3. Caso ortotrópico e implementación de anisotropía total

La extensión al caso ortotrópico se decidió por tres razones principales. Primero, el caso isotrópico de dos parámetros, con solución inversa cerrada, es demasiado sencillo para discriminar entre modelos de aprendizaje: casi cualquier método no lineal lo resuelve, como muestran los resultados. Segundo, la ortotropía es la clase de simetría de mayor relevancia tecnológica después de la isotropía, pues describe laminados compuestos, madera, hueso cortical y metales con textura de laminación [6]. Tercero, la ortotropía introduce condiciones más realistas en la caracterización de materiales, como las restricciones termodinámicas de admisibilidad sobre el espacio de parámetros [11] y el problema de identificabilidad, que obliga a diseñar el protocolo experimental (tres ensayos uniaxiales) en función de qué parámetros se desea recuperar.

El salto a la anisotropía total elevaría el problema de 6 a 21 parámetros y exigiría cambios en las tres áreas mencionadas. En el frente experimental, ningún conjunto de ensayos uniaxiales alineados basta: el tensor triclinico acopla esfuerzos normales con deformaciones cortantes, por lo que se requerirían ensayos multiaxiales o fuera de eje, y en la práctica mediciones de campo completo por correlación digital de imágenes sobre geometrías con campos heterogéneos, que activan simultáneamente muchas componentes del tensor [4]. En el frente del problema directo, dejaría de existir solución analítica para generar el conjunto de entrenamiento, de modo que cada muestra requeriría una solución de elementos finitos completa, incrementando el costo de generación de datos varios órdenes de magnitud y convirtiendo el balance entre tamaño de muestra y precisión en la decisión central del diseño. En el frente del modelo, las entradas dejarían de ser cinco o doce promedios escalares para convertirse en campos completos de deformación, lo que favorecería arquitecturas con sesgos inductivos espaciales, como las redes convolucionales sobre los campos o las redes informadas por la física que incorporan la ecuación de equilibrio como restricción. El presente trabajo deja preparada la infraestructura para su implementación; el solucionador de elementos finitos elimina la barrera de licencias que limitaría la generación masiva de datos, y la comparación sistemática indica que el esfuerzo debe concentrarse en las familias de modelos globales.

### 6.4. Limitaciones y sensibilidad a parámetros

El estudio presenta cuatro limitaciones principales. Primera, los módulos cortantes ortotrópicos no se identifican, por la restricción de identificabilidad del protocolo de ensayos uniaxiales ya discutida.

Segunda, los datos ortotrópicos de entrenamiento y prueba provienen del modelo analítico con ruido y no de simulaciones de elementos finitos, pues el solucionador implementado se limita al caso isotrópico; la validación cruzada entre fuentes de datos independientes, realizada en el caso isotrópico, queda pendiente para el ortotrópico. Tercera, los elementos  $P_1$  imponen un sesgo de discretización del orden del 1 % que domina el error final de los mejores modelos; elementos cuadráticos o mallas más finas desplazarían ese límite. Cuarta, el ruido se modeló como gaussiano relativo e independiente entre características, mientras que el ruido experimental real podría presentar correlaciones espaciales o de otros tipos aquí no simuladas.

La sensibilidad de los resultados a los hiperparámetros se exploró durante el desarrollo: la arquitectura de la red influye de manera visible (la MLP de una capa pierde un orden de magnitud de precisión frente a las de dos y tres capas en el caso isotrópico), mientras que el desempeño es robusto frente a la semilla aleatoria y al número de particiones de la validación cruzada, como indica la baja dispersión del RMSE entre particiones en todas las configuraciones.

## 7. Conclusiones

Se implementó y validó un flujo de trabajo completamente abierto y reproducible para la identificación inversa de parámetros elásticos, que abarca desde la generación de datos mediante un solucionador propio de elementos finitos hasta la comparación sistemática de ocho modelos de aprendizaje automático en dos clases de simetría material. El solucionador reproduce la solución analítica de compresión uniaxial con errores del orden del 1 % y genera las 400 simulaciones del estudio en menos de cuatro minutos, demostrando que la dependencia de software comercial es prescindible para esta clase de problemas.

En el problema isotrópico, todos los modelos no lineales identifican  $E$  y  $\nu$  con errores bajos, y los mejores (aumento de gradiente y la red de tres capas) operan en el límite impuesto por el sesgo de discretización de los propios datos, con errores del 1,3 % en  $E$  y menores al 1,3 % en  $\nu$  sobre los campos de elementos finitos de los cuatro materiales de ingeniería evaluados. La regresión lineal, con errores superiores al 20 %, confirma cuantitativamente la no linealidad esencial del mapeo inverso.

En el problema ortotrópico de seis parámetros, la comparación revela una divergencia cualitativa entre familias de modelos: los métodos locales (KNN y bosques aleatorios) pierden efectividad en el caso ortotrópico, mientras que el aumento de gradiente y las redes neuronales profundas mantienen errores del 2 al 3 % en los seis parámetros. Este hallazgo, junto con el análisis de identificabilidad que motivó el protocolo de tres ensayos, constituye el aporte central del proyecto: establece que la elección de la familia de modelo es la decisión crítica al escalar la identificación de parámetros hacia clases de simetría tecnológicamente relevantes, e implementa la metodología necesaria para la implementación del caso totalmente anisotrópico, donde la generación de datos por elementos finitos, las mediciones de campo completo y las arquitecturas con estructura espacial se vuelven indispensables.

## Referencias

- [1] W. M. Lai, D. Rubin y E. Krempl, *Introduction to continuum mechanics*, 4th ed. Amsterdam ; Boston: Butterworth-Heinemann/Elsevier, 2010, ISBN: 978-0-7506-8560-3.
- [2] S. P. Timoshenko y J. N. Goodier, *Theory of Elasticity*, 3.<sup>a</sup> ed. New York: McGraw-Hill, 1970, ISBN: 978-0-07-064720-6.
- [3] M. Bonnet y A. Constantinescu, «Inverse problems in elasticity,» *Inverse Problems*, vol. 21, n.º 2, R1, feb. de 2005. DOI: [10.1088/0266-5611/21/2/R01](https://doi.org/10.1088/0266-5611/21/2/R01). dirección: <https://doi.org/10.1088/0266-5611/21/2/R01>.
- [4] S. Avril et al., «Overview of identification methods of mechanical parameters based on full-field measurements,» *Experimental Mechanics*, vol. 48, n.º 4, págs. 381-402, 2008. DOI: [10.1007/s11340-008-9148-y](https://doi.org/10.1007/s11340-008-9148-y).
- [5] G. Yagawa y H. Okuda, «Neural networks in computational mechanics,» *Archives of Computational Methods in Engineering*, vol. 3, n.º 4, págs. 435-512, 1996. DOI: [10.1007/BF02818935](https://doi.org/10.1007/BF02818935).
- [6] T. C. T. Ting, *Anisotropic Elasticity: Theory and Applications*. New York: Oxford University Press, 1996, ISBN: 978-0-19-507447-5. DOI: [10.1093/oso/9780195074475.001.0001](https://doi.org/10.1093/oso/9780195074475.001.0001).
- [7] C. R. Harris et al., «Array programming with NumPy,» *Nature*, vol. 585, n.º 7825, págs. 357-362, 2020. DOI: [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2).
- [8] P. Virtanen et al., «SciPy 1.0: Fundamental algorithms for scientific computing in Python,» *Nature Methods*, vol. 17, n.º 3, págs. 261-272, 2020. DOI: [10.1038/s41592-019-0686-2](https://doi.org/10.1038/s41592-019-0686-2).
- [9] F. Pedregosa et al., «Scikit-learn: Machine learning in Python,» *Journal of Machine Learning Research*, vol. 12, págs. 2825-2830, 2011.
- [10] T. Gustafsson y G. D. McBain, «scikit-fem: A Python package for finite element assembly,» *Journal of Open Source Software*, vol. 5, n.º 52, pág. 2369, 2020. DOI: [10.21105/joss.02369](https://doi.org/10.21105/joss.02369).
- [11] B. M. Lempriere, «Poisson's ratio in orthotropic materials,» *AIAA Journal*, vol. 6, n.º 11, págs. 2226-2227, 1968. DOI: [10.2514/3.4974](https://doi.org/10.2514/3.4974).
- [12] O. C. Zienkiewicz, R. L. Taylor y J. Z. Zhu, *The Finite Element Method: Its Basis and Fundamentals*, 7.<sup>a</sup> ed. Oxford: Butterworth-Heinemann, 2013, ISBN: 978-1-85617-633-0.
- [13] L. Breiman, «Random forests,» *Machine Learning*, vol. 45, n.º 1, págs. 5-32, 2001. DOI: [10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- [14] J. H. Friedman, «Greedy function approximation: A gradient boosting machine,» *The Annals of Statistics*, vol. 29, n.º 5, págs. 1189-1232, 2001. DOI: [10.1214/aos/1013203451](https://doi.org/10.1214/aos/1013203451).
- [15] K. Hornik, M. Stinchcombe y H. White, «Multilayer feedforward networks are universal approximators,» *Neural Networks*, vol. 2, n.º 5, págs. 359-366, 1989. DOI: [10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8).
- [16] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. Cambridge, MA: MIT Press, 2016, ISBN: 978-0-262-03561-3.

- [17] D. P. Kingma y J. Ba, «Adam: A method for stochastic optimization,» en *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, San Diego, CA, 2015. DOI: [10 . 48550/arXiv.1412.6980](https://doi.org/10.48550/arXiv.1412.6980).

## A. Apéndices

### A.1. Acceso al repositorio

El código se encuentra en el siguiente repositorio de [GitHub](#).